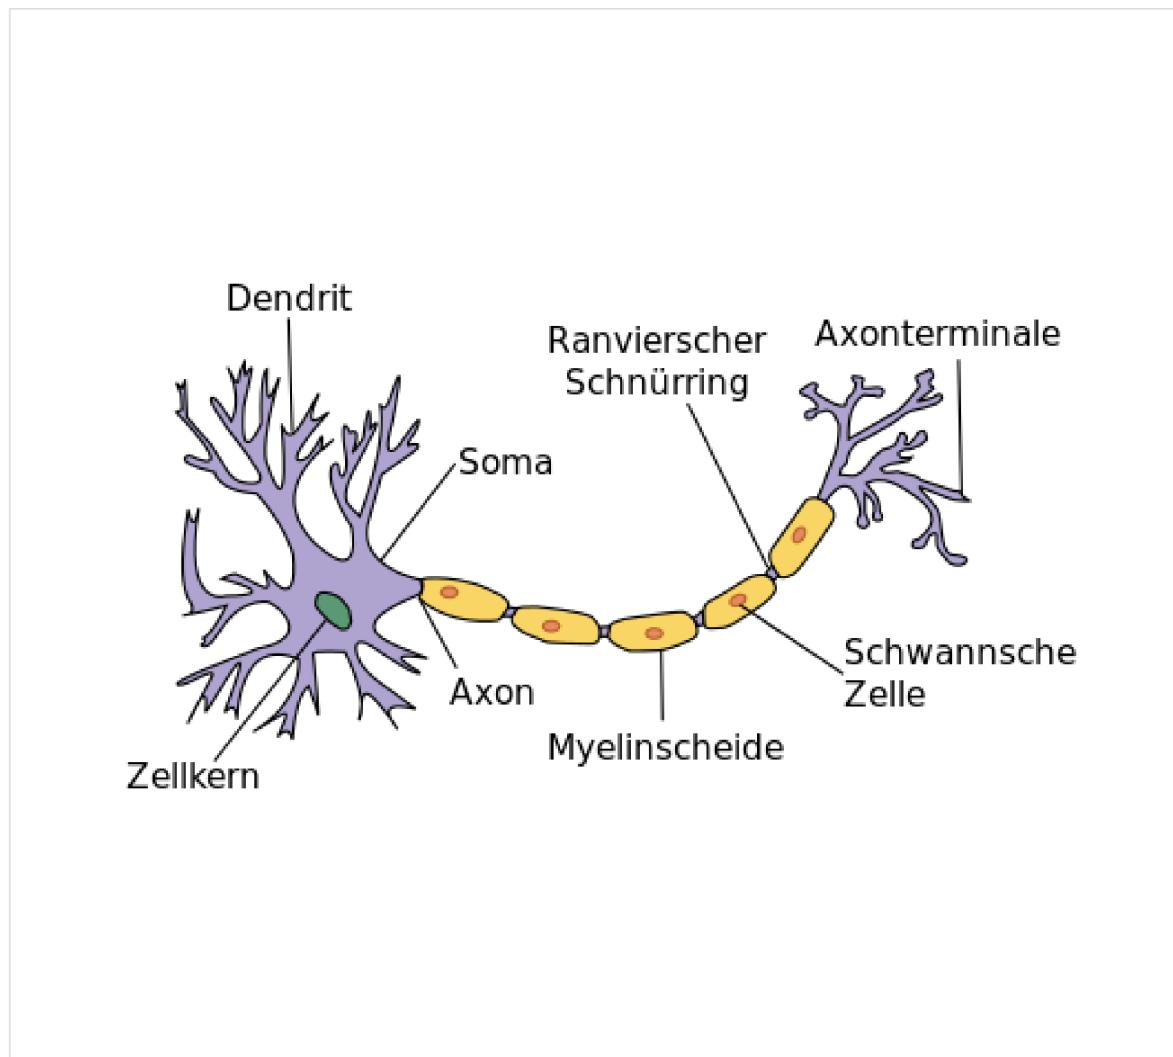
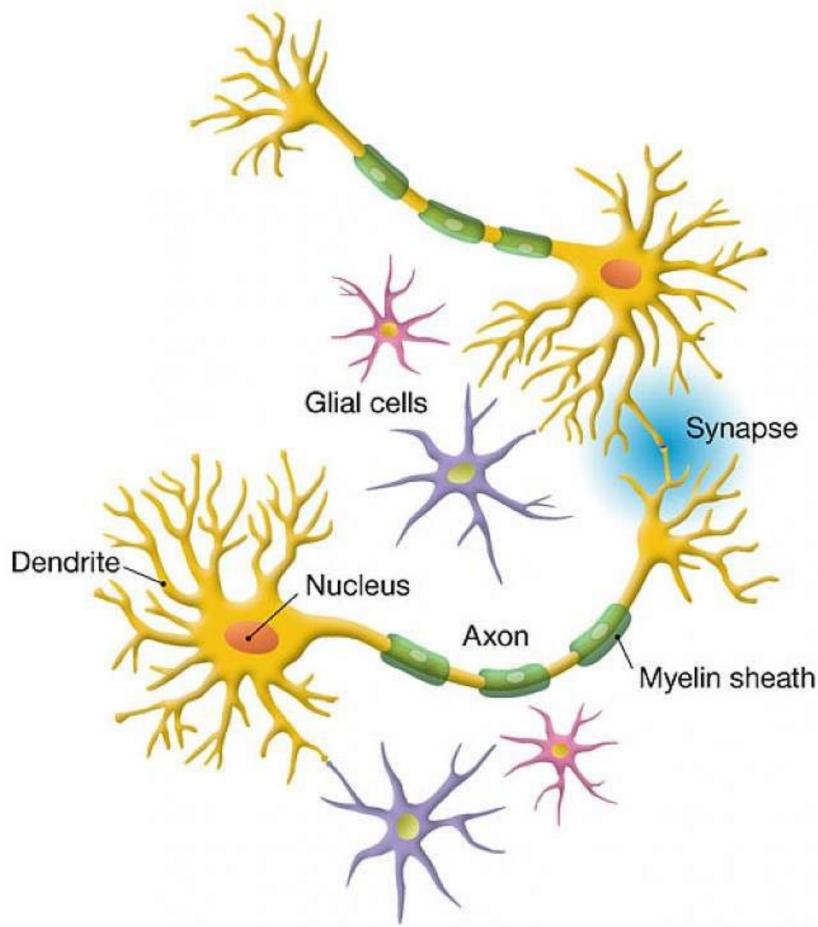


## Neural Networks - retele neuronale

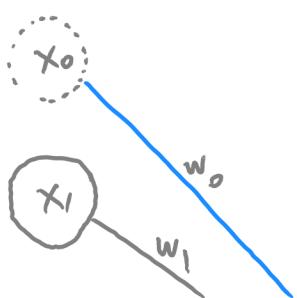
Retelele neuronale in invatarea automata sunt inspirate de structura neuronilor. Sa ne amintim cum arata un neuron.

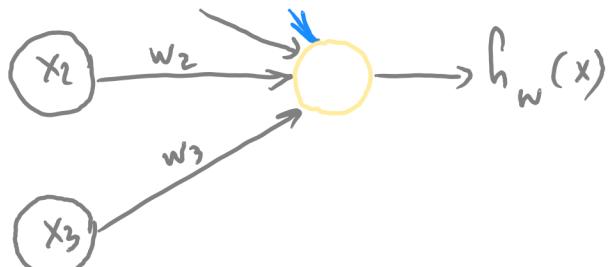


Apropo, comunicarea intre neuroni are loc pe baza de impuls electronic.



Intr-o retea neuronală artificială noi vom face ceva foarte similar cu ceea ce face o retea neuronală adevarată, însă un model mult mai simplificat.



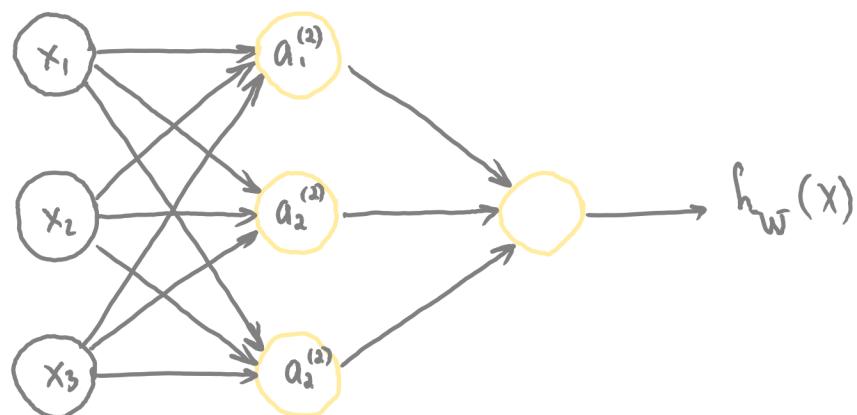


Pentru logistic regression (clasificare liniară)

$$h_w(x) = \frac{1}{1 + e^{-w^T x}}$$

Aceasta este o reprezentare a unui neuron, dar cum arata reprezentarea unei retele neuronale?

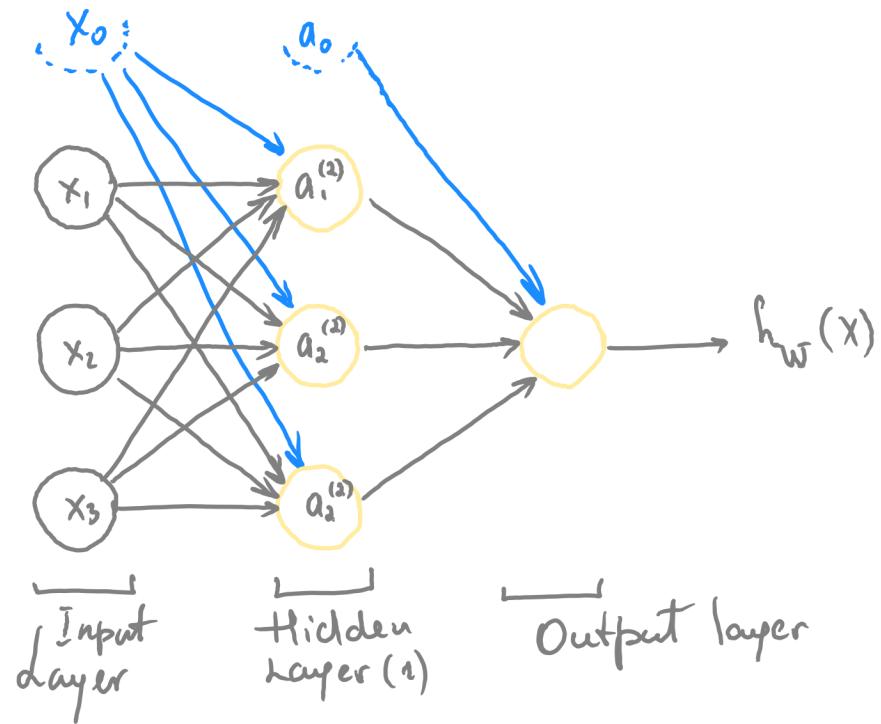
O retea neuronală este pur și simplu un grup de astfel de "neuroni" uniti.



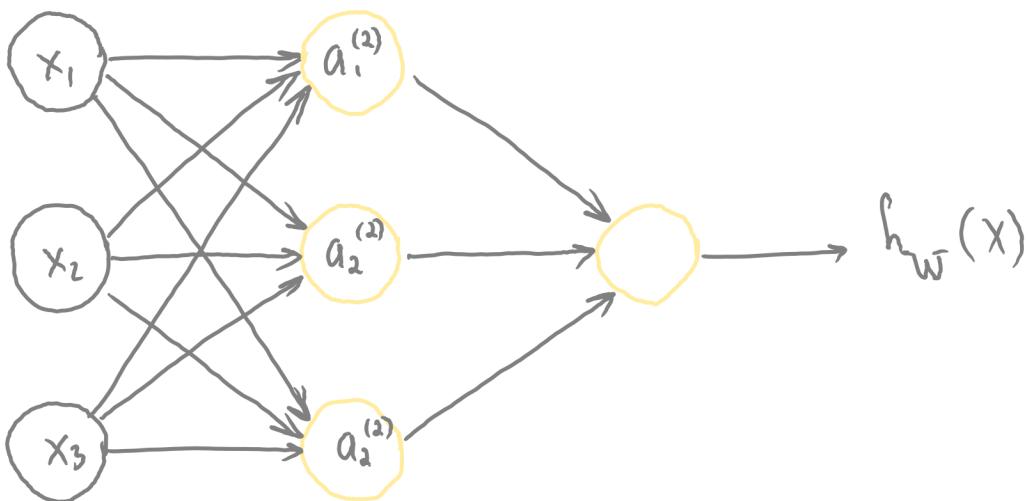
Adesea să reprezint retea neuronală cu sau fără termenul bias:

$x_0$

$a_0^{(2)}$



Pentru a explica calculele din reteaua neuronală voi folosi urmatoarea notație:



$a_i^{(j)}$  - "activarea" unității  $i$  în layerul  $j$

$\bar{W}^{(j)}$  - matricea de parametri (weights)  
care controlează maparea din

care controlă maparea din  
layerul j în layerul j+1

Prin urmare, calculele pentru rețea neuronală de mai sus sunt date de:

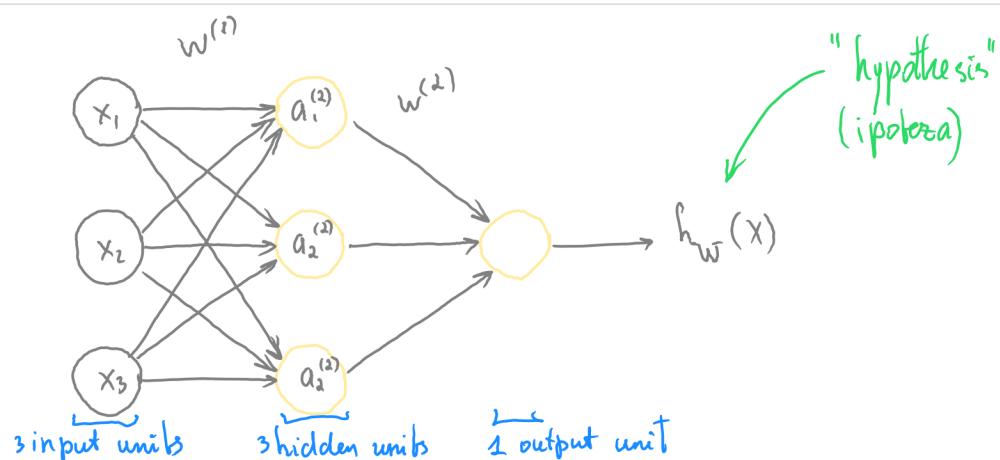
$$a_1^{(2)} = g(w_{10}^{(1)}x_0 + w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + w_{13}^{(1)}x_3)$$

$$a_2^{(2)} = g(w_{20}^{(1)}x_0 + w_{21}^{(1)}x_1 + w_{22}^{(1)}x_2 + w_{23}^{(1)}x_3)$$

$$a_3^{(2)} = g(w_{30}^{(1)}x_0 + w_{31}^{(1)}x_1 + w_{32}^{(1)}x_2 + w_{33}^{(1)}x_3)$$

$$h_w(x) = a_1^{(3)} = g(w_{10}^{(2)}a_0^{(2)} + w_{11}^{(2)}a_1^{(2)} + w_{12}^{(2)}a_2^{(2)} + w_{13}^{(2)}a_3^{(2)})$$

Care ar fi dimensiunile vectorilor W la fiecare layer?



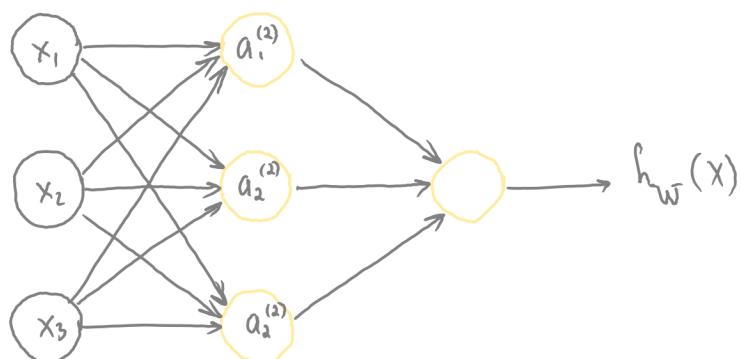
Care este dimensiunea  $w^{(1)}$ ,  $w^{(2)}$  - ?

$$w^{(1)} \in \mathbb{R} \quad w^{(2)} \in \mathbb{R}$$

$\in \mathbb{R}^+$

Dacă o rețea neuronală are  $s_j$  unități în layer-ul  $j$ ,  $s_{j+1}$  unități în layerul  $j+1$ , atunci  $w^{(j)}$  va avea dimensiunea  $\underline{s_{j+1}} \times (\underline{s_j} + 1)$

Având ipoteza noastră definită, să ne uităm cum are loc "trecerea" datelor prin rețea (forward pass):



Arând:

$$a_1^{(2)} = g(w_{10}^{(1)} x_0 + w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2 + w_{13}^{(1)} x_3)$$

$$a_2^{(2)} = g(w_{20}^{(1)} x_0 + w_{21}^{(1)} x_1 + w_{22}^{(1)} x_2 + w_{23}^{(1)} x_3)$$

$$a_3^{(2)} = g(w_{30}^{(1)} x_0 + w_{31}^{(1)} x_1 + w_{32}^{(1)} x_2 + w_{33}^{(1)} x_3)$$

$$h_w(x) = a_1^{(3)} = g(w_{10}^{(2)} a_0^{(2)} + w_{11}^{(2)} a_1^{(2)} + w_{12}^{(2)} a_2^{(2)} + w_{13}^{(2)} a_3^{(2)})$$

$z_1^{(2)}, z_2^{(2)}, z_3^{(2)}$  - combinații liniare parametrizate ( $w^T x$ )

Dacă e să ne uităm mai departe la

Dacă e să ne uităm mai departe la 

observăm că acesta poate fi scris ca:

$$\underbrace{\begin{bmatrix} w_{10}^{(1)} & w_{11}^{(1)} & w_{12}^{(1)} & w_{13}^{(1)} \\ w_{20}^{(1)} & w_{21}^{(1)} & w_{22}^{(1)} & w_{23}^{(1)} \\ w_{30}^{(1)} & w_{31}^{(1)} & w_{32}^{(1)} & w_{33}^{(1)} \end{bmatrix}}_{\tilde{W}^{(1)}} \underbrace{\begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}}_X = \tilde{W}^{(1)} \cdot X$$

Având notatiile de mai sus  $\tilde{x}_1^{(2)}, \tilde{x}_2^{(2)}, \tilde{x}_3^{(2)}$   
putem scrie:

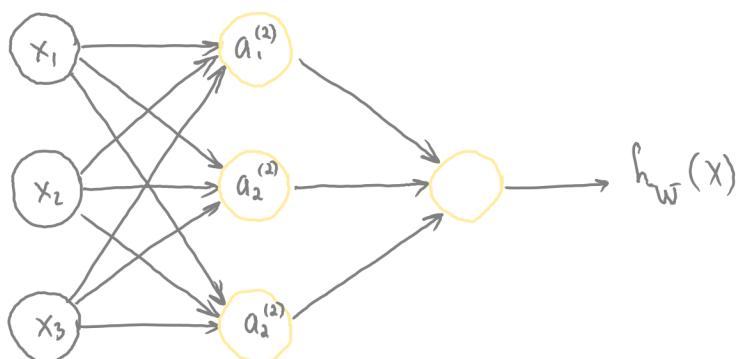
$$\tilde{x}^{(2)} = \begin{bmatrix} \tilde{x}_1^{(2)} \\ \tilde{x}_2^{(2)} \\ \tilde{x}_3^{(2)} \end{bmatrix} = \tilde{W}^{(1)} \frac{X}{a^{(1)}}$$

$$a^{(2)} = g(\tilde{x}^{(2)}) \in \mathbb{R}^3$$

Aceste formule ne ajută să calculăm  $a_1^{(2)}, a_2^{(2)}, a_3^{(2)}$ .

Dar cum rămâne cu termenul bias?

$$x_0 \quad a_0^{(2)}$$



Pentru termenul bias adăugăm  $a_0^{(2)} = 1 > a^{(2)} \in \mathbb{R}^4$

Pentru termenul bias adăugăm  $a_0^{(2)} = 1 \rightarrow a^{(2)} \in \mathbb{R}$

$$z^{(3)} = W^{(2)} a^{(2)}$$

$$h_{\bar{w}}(x) = u^{(3)} = g(z^{(3)})$$

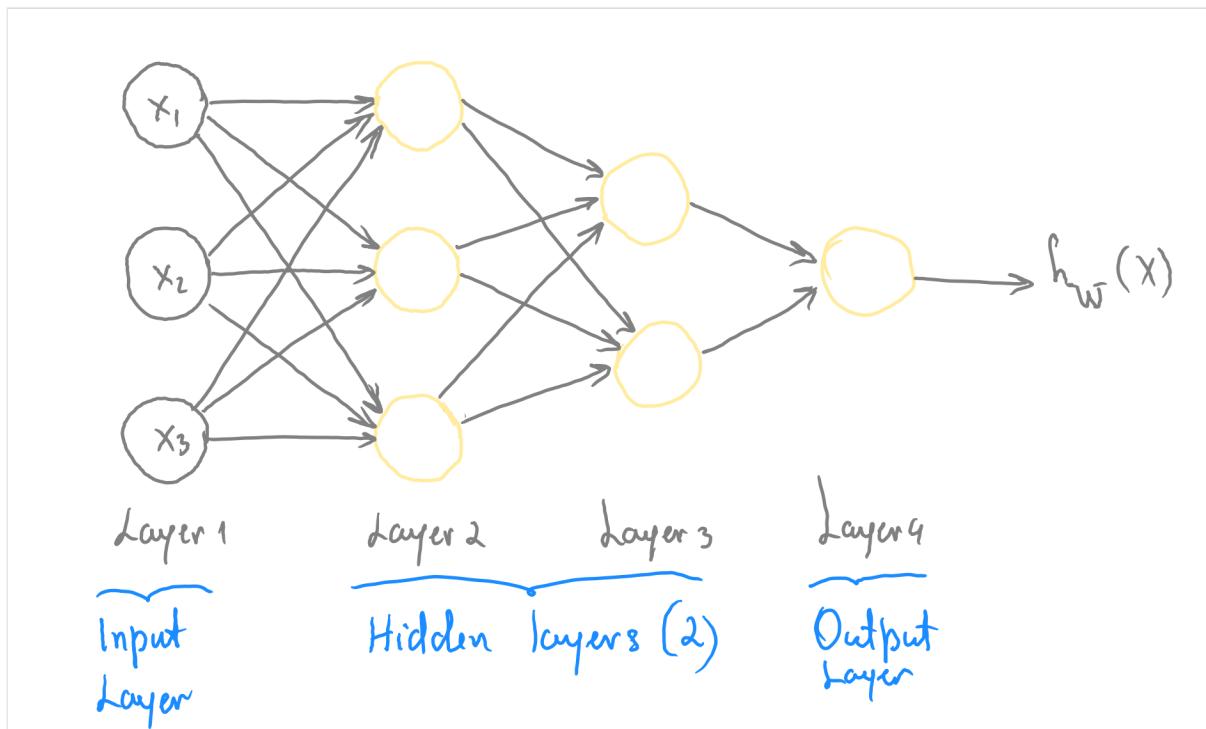
task: de ilustrat

$z^{(3)}$  mai sus

Acest proces de propagare a datelor  $X$  de la stanga la dreapta se numeste "forward propagation".

Idee: explicatie de ce asta se aseamana mult cu logistic regression, si cum NN invata features complexe.

Apropo, diferitiw configuratii a felului cum se conecteaza neuronii formeaza diferite "arhitecturi":



Spre deosebire de modelul anterioare (linear/logistic regression) retelele neuronale se descurca foarte bine la invatarea ipotezelor complexe non-lineare. Sa analizam urmatorul exemplu:

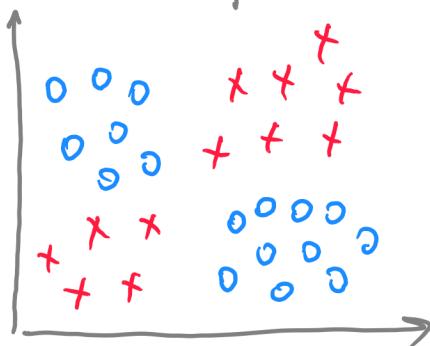
$$\begin{matrix} x_2 \\ 1 \\ 0 \end{matrix}$$

$x_1, x_2$  - binare (0 sau 1)

+

$$\begin{matrix} x_1 \\ 1 \\ 0 \end{matrix}$$

O versiune simplificată a unei probleme fizice:



← frontiera de  
decizie non-lineară

$$\begin{matrix} x_2 \\ 1 \\ 0 \end{matrix}$$

$$y = x_1 \text{ XOR } x_2$$

$$x_1 \text{ XNOR } x_2$$

$$\text{NOT}(x_1 \text{ XOR } x_2)$$

$$\begin{matrix} x_1 \\ 1 \\ 0 \end{matrix}$$

$$\begin{matrix} x \\ 1 \\ 0 \end{matrix} - j = 1 \\ \begin{matrix} 0 \\ 0 \end{matrix} - y = 0$$

Nec amintim:

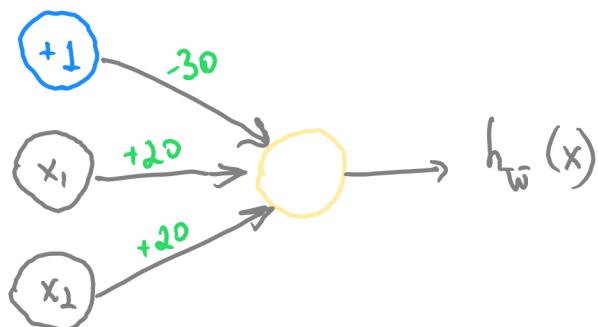
$$x_1 \quad x_2 \mid \text{XOR} \mid \text{NOT XOR} \mid \text{AND}$$

0	0	0	1	0
1	0	1	0	0
0	1	1	0	0
1	1	0	1	1

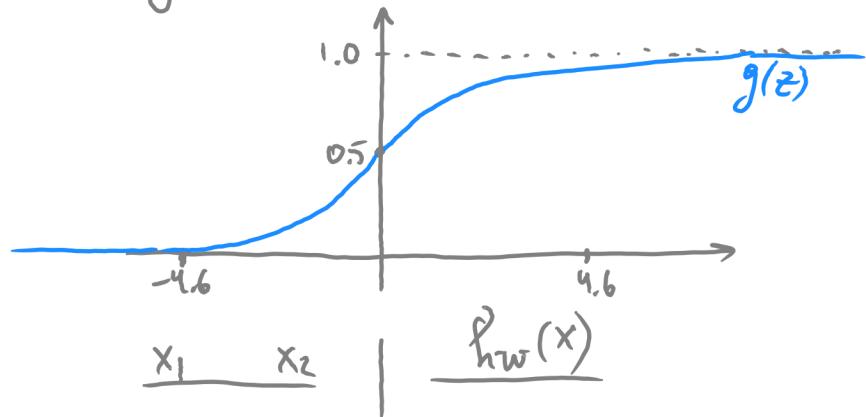
Sa analizam intai un exemplu pentru functia AND:

$$x_1, x_2 \in \{0, 1\}$$

$$y = x_1 \text{ AND } x_2$$

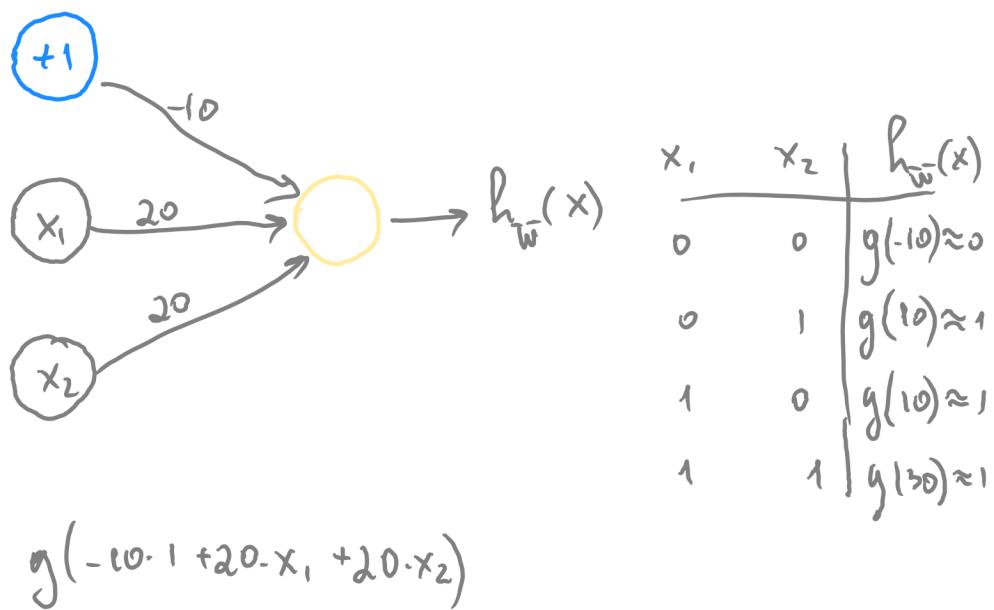


$$h_{\bar{w}}(x) = g(-30 \cdot 1 + 20 \cdot x_1 + 20 \cdot x_2)$$

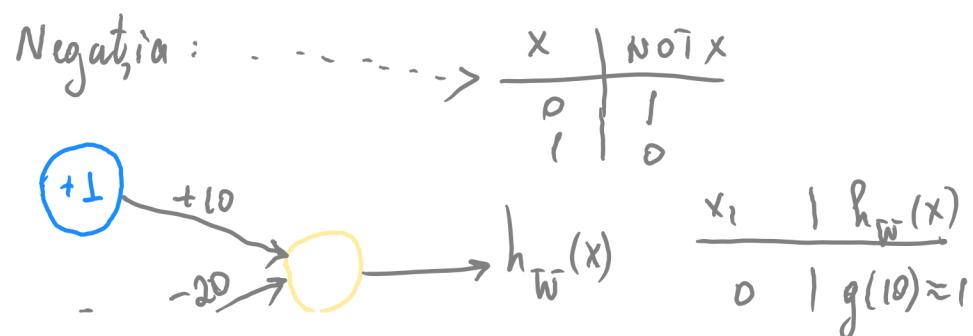


0	0
0	1
1	0
1	1

Dar cum arata acelasi exemplu pentru functia OR?



Cum ar lucra acelasi exemplu pentru functia de "Negatie" - NOT:



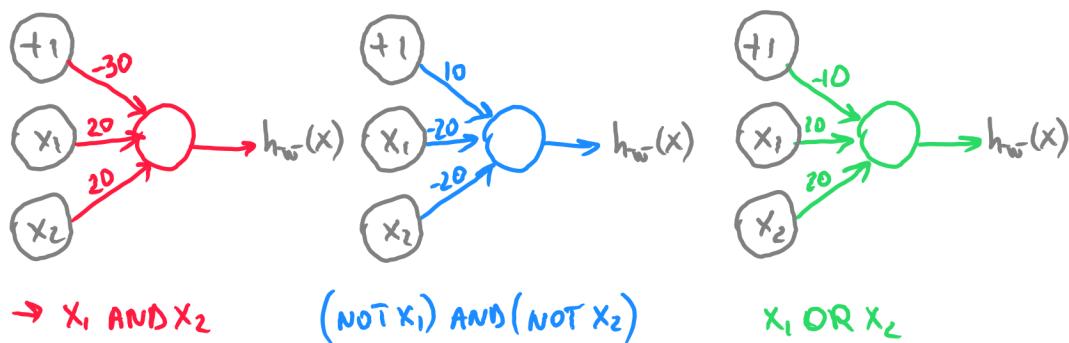
$x_1$

$$\begin{cases} g(10) \approx 1 \\ g(-10) \approx 0 \end{cases}$$

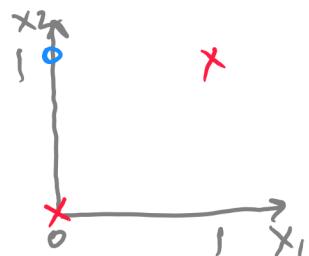
$$h_w(x) = g(10 - 20x_1)$$

⚠ Idee: încercați să reprezentați rețeaua neuronală și găsiți valorile parametrilor pentru  $(\text{NOT } x_1) \text{ AND } (\text{NOT } x_2)$

Având exemplele de mai sus, să unim "puzzleul":

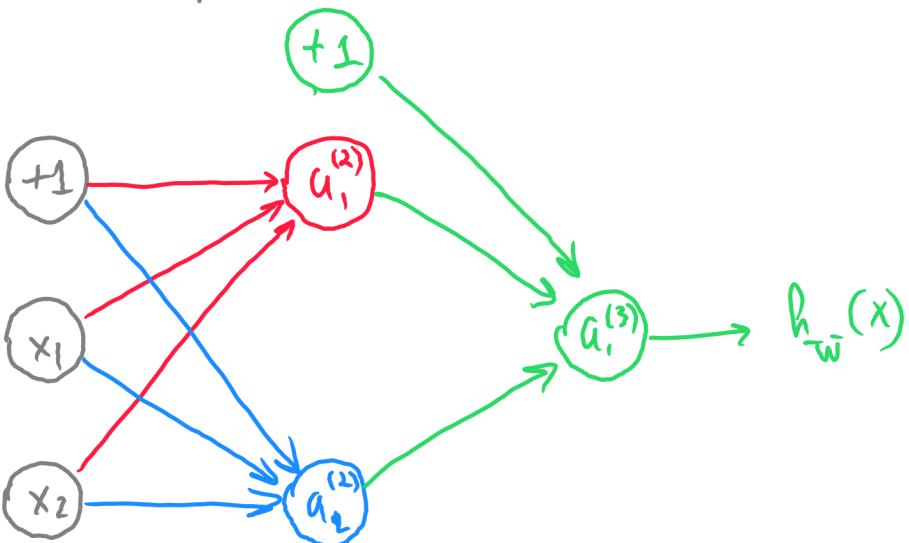


Ne amintim că ceea ce vrem să obținem este o separare nonliniară:



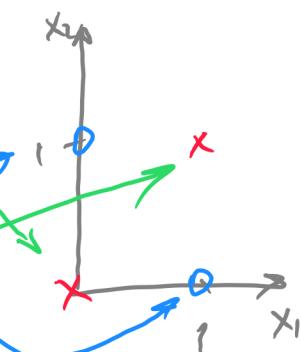
Să reprezentăm rețeaua

Să reprezentăm urmăra:

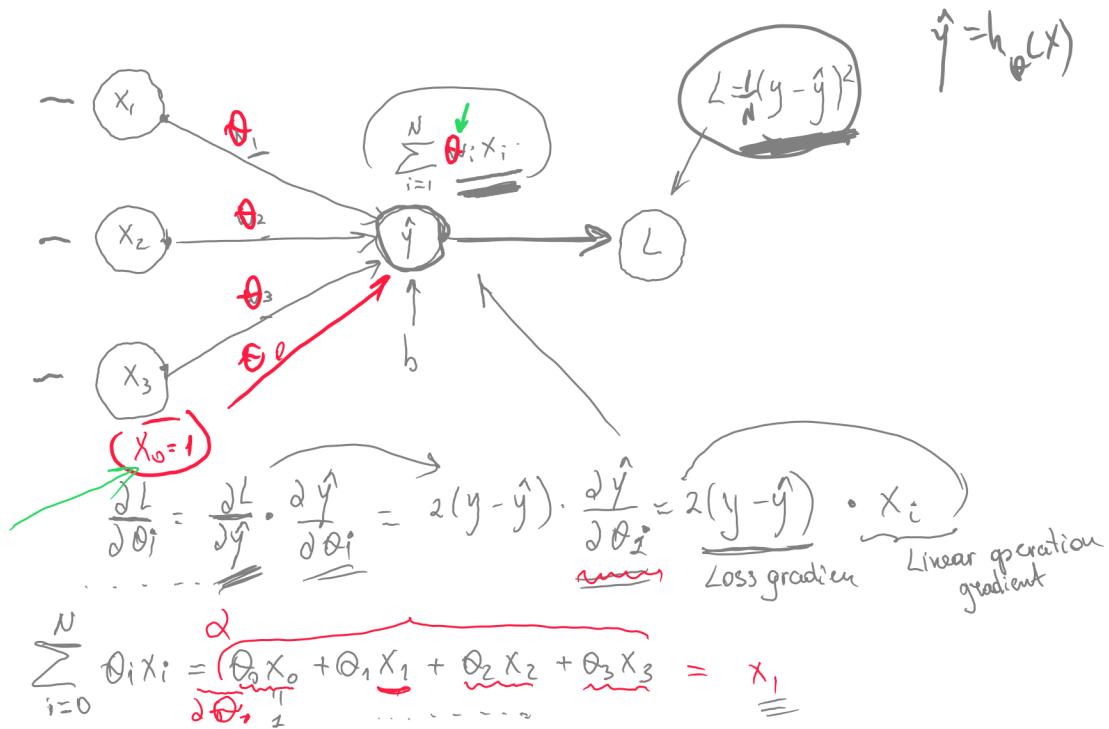


Input Layer      Hidden Layer      Output Layer  
Tabul de aderă

$x_1$	$x_2$	$a_1^{(2)}$	$a_2^{(2)}$	$h_{\bar{w}}(x)$
0	0	0	1	1
0	1	0	0	0
1	0	0	0	0
1	1	1	0	1

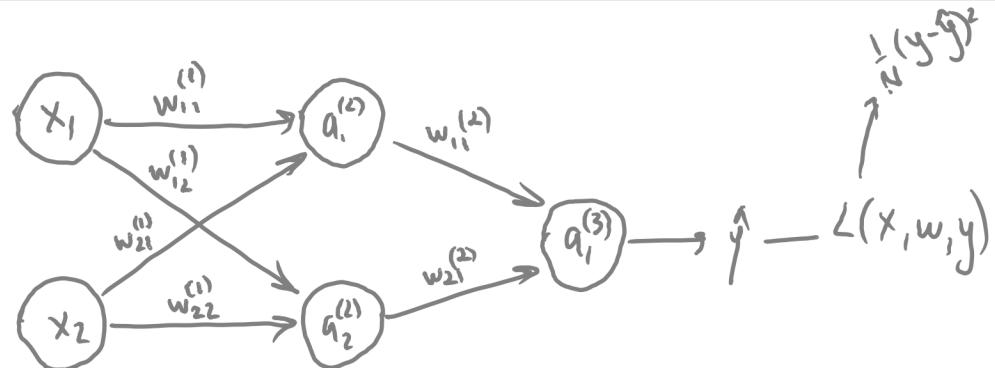


Acum avem parametrii  $w$  "optimali". Dar cum aflam acești parametri în alte probleme pe care încercăm să le rezolvăm? Sa ne amintim de lectia de linear regression:



todo: definirea linear regression cu notatia de mai sus. Rescrierea derivarii.

Cum se aplica asta la retele "mai complicate"?



Layer 1      Layer 2      Layer 3       $g = \sigma(w^T a)$

$$a_1^{(3)} = g\left(w_1^{(2)} a_1^{(2)} + w_2^{(2)} a_2^{(2)}\right)$$

$$w_1^{(2)} = \frac{\partial L}{\partial w_1^{(2)}} = \frac{\partial L}{a_1^{(3)}} \cdot \frac{\partial a_1^{(3)}}{\partial g} \cdot \frac{\partial g}{\partial w_1^{(2)}}$$

loss.backward()

linear2.backward()

activation.backward()